

¿CÓMO SUENA UNA GOTA QUE RUEDA? UN MARCO PARAMÉTRICO FÍSICAMENTE INFORMADO PARA LA SÍNTESIS DE SONIDOS IMPOSIBLES

PACS: 43.60.Lq, 43.58.Ta, 43.66.Lj

[Doble ciego: autores y afiliaciones se añaden tras revisión]

Palabras clave: síntesis de sonido, Foley, física-DSP, sonidos imposibles, DDSP, inversión de parámetros

RESUMEN

El diseño sonoro audiovisual requiere con frecuencia combinaciones materia–interacción que no ocurren en la naturaleza: una gota líquida que rueda, un impacto rocoso húmedo, grava raspando bajo agua. Los enfoques generativos basados en codificadores neuronales preentrenados permiten manipular el espacio latente y producen variación medible en métricas espectrales, pero raramente se traducen en cambios que el oyente identifique semánticamente como “más líquido” o “más rocoso”. Este trabajo propone un marco paramétrico físicamente informado organizado en capas modulares — síntesis modal, fricción de cuerpo y superficie, granular estocástico, eventos de gota con dinámica de Minnaert — combinadas por un compositor genérico que admite especificaciones de material, interacción y modificadores. Cada parámetro tiene significado físico directo, garantizando que un control “más X” corresponda a una transformación acústica coherente. Como caso paradigmático presentamos la gota rodante, sin referente natural directo. Sobre 75 mediciones (15 pares escena–parámetro por cinco métricas acústicas), 10 de 15 pares producen variación monotónica significativa ($|\rho_{\text{Spearman}}| > 0,7$); de los cinco restantes, cuatro corresponden a parámetros sin efecto en su escena. Una contraparte diferenciable del motor permite recuperar parámetros físicos por descenso de gradiente desde grabaciones, con errores del orden del 1 % o inferiores en gotas e impactos modales. Discutimos el posicionamiento del marco frente al estado del arte reciente en acústica de burbujas acopladas y en modelado físico diferenciable, e identificamos el principal cuello de botella de la inversión — la estimación de frecuencia por descenso de gradiente sobre pérdidas espectrales — como una patología intrínseca que sitúa a la gota rodante en el extremo mal condicionado de un continuo de identificabilidad.

ABSTRACT

Audiovisual sound design routinely requires material–interaction combinations that do not occur in nature: a rolling liquid droplet, a wet rock impact, gravel scraping under water. Generative approaches based on pretrained neural codecs allow latent-space manipulation and yield measurable variation in spectral metrics, but seldom translate into changes that listeners semantically identify as “more liquid” or “more rocky”. We propose a physics-informed parametric framework organised in modular layers — modal resonators, body-and-surface friction, stochastic granular events, droplet events with Minnaert bubble dynamics — combined by a generic composer that accepts material, interaction and modifier specifications. Each parameter has direct physical meaning, so that a “more X” control produces an acoustically coherent transformation. As paradigmatic case we present the *rolling droplet*, which has no direct natural referent. Across 75 measurements (15 scene–parameter pairs over five acoustic metrics), 10 of 15 pairs produce significant monotonic variation ($|\rho_{\text{Spearman}}| > 0,7$); of the remaining five, four correspond to parameters with no effect on their scene. A differentiable counterpart of the engine recovers physical parameters by gradient descent from recordings, with errors at or below the 1 % range on droplet and modal impact events. We position the framework against recent state of the art in coupled-bubble acoustics and differentiable physical modelling, and identify

the main bottleneck of the inverse problem — frequency estimation by gradient descent on spectral losses — as an intrinsic pathology that places the rolling droplet at the ill-conditioned end of an identifiability continuum.

1. INTRODUCCIÓN

El diseño sonoro para cine, animación, videojuegos y medios inmersivos requiere a menudo sonidos que *no* existen como grabaciones. Una animación pide una gota de mercurio que rueda; un equipo de audio para videojuegos necesita grava raspando dentro de una cueva inundada; una pieza experimental busca una roca líquida. Dos rutas han dominado la práctica.

La primera, el **Foley clásico**, combina capas grabadas en estudio que se procesan manualmente. El resultado es de gran calidad pero costoso, lento y poco reproducible: no existe una forma sistemática de pedir “más mojado” o “menos granuloso” sobre un evento existente.

La segunda, los **enfoques generativos neurales** basados en codificadores preentrenados (EnCodec [1], RAVE [2], DAC [3]) o difusión latente condicionada por texto (AudioLDM [4], Stable Audio Open [5]), promete una ruta más rápida. Pero presenta dos limitaciones recurrentes. Primero, los espacios latentes de los codificadores preentrenados están optimizados para *re-construcción general de audio*, no para representar semántica de material o interacción, y sus ejes carecen de anclaje en atributos físicos. Segundo, cuando se manipulan estas representaciones para obtener mezclas tipo “más líquido” o “más rocoso”, el espectro cambia de forma medible (RMS, rango dinámico, centroide), pero el carácter percibido del sonido a menudo *no* cambia: el oyente no oye un líquido donde no lo había [6, 7].

Esta disociación entre *monotonía cuantitativa* en el espacio de métricas y *monotonía perceptual* en el espacio del audio es un obstáculo central para el control interpretable. Proponemos atacar el problema desde el extremo opuesto: en lugar de partir de un espacio latente aprendido y esperar que codifique significado físico, construimos un motor de síntesis paramétrico cuyos controles *son* parámetros físicos por construcción. Bancos de resonadores modales reproducen cuerpos materiales; modelos de fricción reproducen raspados y arrastres; trenes granulares estocásticos reproducen grava y arenas; la resonancia de Minnaert reproduce la formación de burbujas de aire en agua. Un compositor genérico combina estas primitivas a partir de una especificación de material, interacción y modificadores de alto nivel, y expone controles físicos continuos — humedad, granularidad, rigidez, resonancia, continuidad — que el usuario manipula como deslizadores.

El resultado es un marco donde más humedad incrementa la viscosidad de la gota, más granularidad aumenta la rugosidad de la trayectoria de rodadura, y más rigidez desplaza las fundamentales modales hacia arriba: cada control produce una transformación audible coherente con su significado físico. El caso de la **gota rodante** — un sonido sin referente natural que podamos grabar — ilustra el enfoque como un tren cuasi-periódico de contactos modulados por velocidad y rugosidad sobre una sutil cola modal de la superficie.

Las contribuciones de este trabajo son: (i) una biblioteca modular de primitivas físicamente informadas para efectos de sonido (modal, fricción, granular, gota con dinámica de Minnaert, salpicadura y vertido); (ii) un compositor genérico que admite combinaciones materia-interacción imposibles; (iii) un controlador con parámetros físicos y monotónia objetiva demostrable; (iv) un conjunto abierto de 24 estímulos sonoros imposibles con metadatos; (v) una contraparte diferenciable del motor que recupera parámetros físicos por descenso de gradiente desde audio real, sin entrenar ninguna red neuronal; y (vi) el diseño y la infraestructura de un estudio perceptual piloto, actualmente en curso, que contrastará monotónia espectral y monotónia perceptual entre el marco propuesto y un baseline neural.

2. TRABAJO RELACIONADO

Síntesis físicamente basada. La síntesis modal con resonadores es una herramienta clásica para sonidos percusivos y de impacto, y los modelos de líquidos basados en la resonancia de burbuja de Minnaert ($f_M = 3,26/r$ para una burbuja de aire en agua, con r en metros) son el fundamento canónico del sonido de gotas y flujos [8, 9, 10]. En particular, van den Doel [9] muestra que sonidos líquidos complejos (lluvia, arroyos, vertidos) se sintetizan como superposición granular de burbujas individuales gobernadas por un modelo estadístico de población — el paradigma de *modelado sónico físicamente informado* que adoptamos para nuestras capas granulares. El estado del arte en acústica de fluidos ha avanzado, sin embargo, más allá de la burbuja única: se modelan el acoplamiento entre burbujas, responsable del contenido de baja frecuencia más rico de las nubes de burbujas [11], los desplazamientos de frecuencia por forma y proximidad a interfaces mediante métodos de capacitancia, y la dinámica topológica de nacimiento, división, fusión y estallido [12]. Como ruta de mayor fidelidad, la síntesis numérica por diferencias finitas en el dominio del tiempo [13] simula directamente las ecuaciones en derivadas parciales del medio, a un coste computacional mucho mayor. Nuestro motor se sitúa deliberadamente en el régimen analítico/modal, ligero y en tiempo real, asumiendo la burbuja de Minnaert como aproximación de primer orden.

Síntesis neural de efectos de sonido. Los codificadores preentrenados codifican audio arbitrario en latentes compactos, y trabajos recientes exploran la controlabilidad dentro de estos latentes [15, 16]. Los modelos de difusión condicionados por texto aceptan descripciones en lenguaje natural y producen salidas plausibles pero opacas. Frente a ellos, nuestro marco prioriza la interpretabilidad y la reproducibilidad sobre la generalidad.

Morphing e infusión. SoundMorpher [17] introduce criterios explícitos de correspondencia, intermediación y suavidad en el morphing de audio, y los modelos basados en CLAP [18] permiten medir alineamiento semántico entre audio y texto. Tomamos prestado el criterio de intermediación como una de nuestras métricas objetivas.

Modelado diferenciable. El paradigma DDSP [19] reformula bloques de procesamiento clásico como operaciones diferenciables. El estado del arte reciente en modelado físico diferenciable acopla el renderizado diferenciable con componentes neuronales y de elementos finitos para resolver problemas inversos de material, forma y excitación [20, 21]. Nuestro marco comparte el paradigma de inversión por gradiente pero es *deliberadamente no entrenado*: los parámetros físicos se exponen directamente y la inversión opera sobre el motor diferenciable, sin red neuronal en el camino, lo que delimita una posición minoritaria pero plenamente interpretable dentro de este espacio.

3. MÉTODO

3.1. Capas primitivas

Síntesis modal. Un cuerpo material se modela como suma de sinusoides amortiguadas excitadas por un impulso corto. Cada perfil material define el número de modos, la frecuencia fundamental, el espaciado armónico, el tiempo de decaimiento, la inarmonicidad y la forma espectral. Proveemos perfiles calibrados para metal, roca, madera, cristal, tierra y tela, ampliados con un catálogo extendido para materiales exóticos.

Fricción. Los eventos de raspado y arrastre se modelan como ruido de banda modulado por una envolvente de velocidad fluctuante y enrutado a través de la resonancia del cuerpo del material. La rugosidad añade micro-pulsos estocásticos, y un modelo de *stick-slip* introduce eventos discretos de desprendimiento sobre la envolvente continua [14].

Flujos granulares. Grava, arena y tierra se modelan como nubes estocásticas de micro-impactos modales, donde cada grano es un golpe modal corto cuya fundamental escala in-

versamente con el tamaño del grano. Disponemos de un catálogo de perfiles minerales y de texturas extremas (hielo, nieve, ceniza).

Evento de gota. Un impacto de gota se compone de un ataque impulsivo, un chirp ascendente de formación de burbuja de alto factor de calidad cuya frecuencia central deriva del radio mediante la relación de Minnaert, una envolvente exponencial de decaimiento y una cola modal opcional de la superficie de impacto. El amortiguamiento de la burbuja se acopla a su radio siguiendo la ley de van den Doel [9], de modo que las gotas pequeñas decaen más rápido que las grandes. La viscosidad ralentiza el chirp y acorta el decaimiento.

Gota rodante. Un tren cuasi-periódico de contactos de gota con jitter temporal (rugosidad de la trayectoria) y jitter de amplitud (dinámica de rodadura), sumado a un lecho de ruido coloreado modulado por la envolvente del tren. Sus grados de libertad son físicos: radio de la gota, viscosidad, dureza de la superficie, velocidad de rodadura y rugosidad de la trayectoria.

Salpicadura y vertido. Una salpicadura es un estallido de banda corto seguido de un conjunto de impactos de gota dispersos con una distribución controlable de tamaños de burbuja. Un vertido es un tren denso de gotas con turbulencia de banda superpuesta.

3.2. Compositor y control físico

El compositor traduce una especificación de alto nivel — material, interacción y modificadores — en la primitiva o combinación de primitivas adecuada, mapeando cada par materia-interacción a su generador (Tabla 1) y convirtiendo los modificadores perceptuales en los parámetros físicos que consume la primitiva activa. Las combinaciones imposibles se realizan por superposición ponderada de dos escenas: un impacto rocoso húmedo combina un impacto de roca con una salpicadura líquida; un raspado de grava mojada combina grava raspando con un vertido líquido; y la gota rodante es una escena directa, pues su imposibilidad es intrínseca a la combinación — los líquidos no ruedan en la naturaleza.

El usuario interactúa mediante controles físicos continuos. Fijada una escena, cada control puede ajustarse a un valor estático o barrerse en un rango, produciendo secuencias de audio cuyo contenido acústico varía coherentemente con el valor del control. Además, los controles pueden seguir envolventes temporales — rampas, decaimientos, oscilaciones — que, mediante síntesis solapada, producen sonidos evolutivos: una gota que se humedece, una rodadura que se acelera, una resonancia que oscila.

Cuadro 1 – Pares (material, interacción) soportados por el compositor.

Material	Interacciones soportadas
roca, metal	impacto, rodadura, raspado (roca también arrastre)
madera	impacto, raspado
tela	arrastre
líquido	gota, salpicadura, vertido, rodadura, impacto
grava	paso, rodadura, raspado, vertido
tierra	paso
<i>Catálogo extendido (materiales exóticos):</i>	
caucho	impacto, rodadura, raspado
hueso, quitina	impacto, raspado
hielo	impacto, raspado, rodadura
plasma	impacto, rodadura (imposible)

4. LA GOTA RODANTE COMO CASO DE ESTUDIO

La pregunta del título — *¿cómo suena una gota que rueda?* — no tiene referente grabable. Construimos el sonido desde abajo: una gota de 2,75 mm de radio rodando a 18 contactos por segundo sobre una superficie semi-dura, con rugosidad de trayectoria moderada. Cada contacto es un chirp en torno a 1,2 kHz (la frecuencia de Minnaert para ese radio) de unos 30 ms, decayendo durante unos 100 ms, con una débil cola metálica de la capa modal de la superficie. Un lecho de ruido coloreado, modulado por la envolvente del contacto, sugiere humedad ambiental. Renderizamos ocho variantes perturbando la configuración canónica para barrer humedad, velocidad de rodadura, granularidad de la trayectoria y tamaño de la gota.

La Figura 1 muestra los espectrogramas de cuatro variantes. La gota canónica exhibe un tren periódico de chirps en la banda 1–2 kHz; la variante muy húmeda desplaza el centroide hacia abajo y extiende los decaimientos; la rodadura lenta separa los contactos en eventos claramente identificables; y la rodadura rápida los colapsa en una textura casi continua.

Fig. 2. Spectrograms of four rolling-droplet variants generated by the parametric framework




Figura 1 – Espectrogramas de cuatro variantes de la gota rodante generadas por el marco paramétrico.

5. EVALUACIÓN

5.1. Corpus de estímulos

Renderizamos 24 estímulos agrupados como tres escenas por ocho variantes: una gota rodante, un impacto rocoso húmedo (impacto de roca con superposición de salpicadura líquida de peso variable) y un raspado de grava mojada (grava raspando bajo superposición de vertido líquido). Todos los estímulos son de 5 s, mono, 44,1 kHz, normalizados a 0,95 de pico ($\approx -0,45$ dBFS), y se acompañan de un registro con todos los parámetros y métricas de calidad por clip.

5.2. Métricas objetivas

Computamos seis métricas acústicas en cada audio: RMS y pico en dBFS, factor de cresta, planitud espectral, centroide espectral y rango dinámico. Un veredicto de calidad compuesto en {bueno, sospechoso, defectuoso} integra las métricas con umbrales calibrados para detectar silencios, ausencia de transitorios, ruido blanco o siseo aislado. La Tabla 2 compara el marco físico con baselines neurales sobre rangos métricos idénticos.

El marco físico, ambos baselines neurales y el baseline aditivo pasan el veredicto al 100 % (Figura 4). El baseline de interpolación lineal falla en 5 de 6 casos, como anticipa el criterio de intermediación.

Cuadro 2 – Comparación maestra de métodos sobre generaciones de sonidos imposibles.

Método	n	% bueno	dyn (dB)	RMS (dB)	centroide (Hz)
Físico (24 variantes)	24	100,0	36,1	−25,1	3282
Neural A (dirección latente)	162	100,0	45,8	−28,6	4002
Neural B (edición por gradiente)	24	100,0	59,2	−32,8	2987
Baseline suma aditiva	6	100,0	11,2	−17,3	451
Baseline interpolación lineal	6	16,7	38,9	−48,2	3409

5.3. Monotonía

Para cada par (escena, parámetro) renderizamos siete estímulos barriendo el parámetro de 0 a 1 con los demás fijados en su valor central, y computamos la correlación de Spearman entre el valor del parámetro y cinco métricas acústicas: RMS, rango dinámico, centroide espectral, planitud espectral y distancia log-espectral al estímulo central. Un par es *monotónico* si al menos una métrica satisface $|\rho| > 0,7$. De los 15 pares (tres escenas por cinco parámetros), diez son monotónicos. De los cinco restantes, cuatro corresponden a parámetros sin efecto alguno en su escena ($\rho = 0$ exacto): la resonancia en la gota rodante y en el raspado de grava (ni la gota ni los eventos granulares tienen resonancia de cuerpo ajustable), la rigidez en el raspado de grava y la granularidad en el impacto rocoso (la granularidad es un atributo de los flujos, no de impactos únicos). El quinto, la continuidad en el raspado de grava, produce variación acústica pero por debajo del umbral ($|\rho|_{\text{mx}} = 0,54$). Cabe destacar la rigidez en la gota rodante: el motor la reutiliza como radio inverso de la gota (una gota más “rígida” se modela más pequeña), por lo que resulta fuertemente monotónica vía la relación de Minnaert ($|\rho|_{\text{mx}} = 0,89$; centroide 0,86). La Figura 2 reporta el mapa de calor de $|\rho|_{\text{mx}}$ por par, y la Figura 3 muestra cinco barridos monotónicos representativos.

Fig. 3. Monotonicity of physical knobs: 10 of 15 (scene, knob) pairs reach $|\rho| > 0.7$




Figura 2 – Monotonía de los parámetros físicos: 10 de 15 pares (escena, parámetro) alcanzan $|\rho| > 0,7$.

Fig. 4. Five monotonic sweeps; each physical knob produces an audible, ordered effect




Figura 3 – Cinco barridos monotónicos: cada parámetro físico produce un efecto audible y ordenado.

Crucialmente, los barridos de dirección latente neural — re-medidos sobre cuatro combinaciones disponibles de experimentos previos — son también monotónicos en métricas espectrales (4 de 4). El marco físico y los baselines neurales son, por tanto, indistinguibles en este test objetivo de monotonía. Lo que los separa es si la monotonía espectral se traduce en monotonía perceptual, cuestión que aborda el estudio piloto.

5.4. Estudio perceptual piloto

Diseñamos un experimento de escucha en el que cada oyente evalúa la mitad de los 24 estímulos en orden aleatorizado. Tras cada estímulo se recogen cuatro respuestas: material percibido, interacción percibida, grado de imposibilidad en escala Likert de 1 a 7 y coherencia como evento único en escala de 1 a 7. Para cada escena se compararán las tasas de identificación frente a una verdad de campo permisiva (cualquiera de los componentes del imposible cuenta como acierto), pruebas de Friedman sobre las variantes para imposibilidad y coherencia, y la correlación de Spearman entre el valor del parámetro físico y la mediana de imposibilidad percibida a través de las variantes — el test de monotonía perceptual propiamente dicho.

Los resultados del piloto se incorporarán a esta sección en la versión final del artículo cuando el número de oyentes alcance el umbral previsto.

6. RECUPERACIÓN DIFERENCIABLE DE PARÁMETROS

Una contraparte completamente diferenciable del motor permite *invertir* cualquier audio objetivo hacia los parámetros físicos del marco. Reescribimos las primitivas principales como un grafo de cómputo diferenciable, de modo que el gradiente de una pérdida espectral fluye hasta cada parámetro físico, y recuperamos dichos parámetros minimizando una pérdida de STFT multi-resolución con descenso de gradiente y una tasa de aprendizaje suficientemente lenta. Los resultados son cualitativamente distintos por primitiva (Tabla 3).

- **Gota:** con una inicialización físicamente razonable, el radio se recupera con error inferior al 0,05 % y la viscosidad por debajo del 0,2 %, igual que los parámetros auxiliares del chirp y el decaimiento.
- **Modal:** la clave es inicializar las frecuencias modales en los picos espectrales dominantes del objetivo; con esa siembra, las frecuencias se recuperan con error inferior al 0,3 % y los tiempos de decaimiento en torno al 1 % (máximo 1,3 %).
- **Granular:** matemáticamente mal condicionado, pues el espectro granular es una textura difusa sin picos discretos y desplazamientos opuestos de la frecuencia base y la dispersión se compensan; la dispersión se recupera bien ($< 0,5$ %) pero la frecuencia base permanece sesgada (~ 60 %) incluso con inicialización espectral, precisamente por esa redundancia.
- **Reverberación:** la convolución es nativamente diferenciable y la respuesta al impulso se aprende con un prior de dispersión; recupera la magnitud espectral pero no la fase, suficiente para resíntesis pero no para deconvolución literal.
- **Fricción:** la dureza de superficie se recupera con error del orden del 1,5 % y la velocidad media en torno al 4 %; el decaimiento del cuerpo tiende a colapsar porque la pérdida espectral es poco sensible a decaimientos modales muy cortos.

Este continuo — de recuperación quirúrgica (gota, modal) a honestamente mal condicionada (granular) — es en sí mismo un resultado: distingue qué partes del modelo físico están localmente identificables desde el audio y cuáles requieren conocimiento previo.

El problema inverso de frecuencia. La recuperación parcial observada no es un defecto de implementación sino una patología intrínseca y reconocida: la estimación de parámetros de frecuencia por descenso de gradiente sobre pérdidas espectrales sufre gradientes abruptos o nulos y superficies de error densamente pobladas de mínimos locales [22, 23]. Cuando las frecuencias predichas y objetivo dejan de solaparse, el gradiente de una pérdida de magnitud se anula y el optimizador se estanca. La gota rodante, cuyos cinco controles de alto nivel se despliegan en 16 tensores de parámetros en la contraparte diferenciable (13 optimizados al congelar la superficie), ocupa por ello el extremo mal condicionado de este continuo: su radio incide sobre todo en la frecuencia del tono de cuerpo de Minnaert, un único rasgo espectral que compite con una rica capa modal de superficie, de modo que el mínimo de la pérdida de magnitud no coincide en general con el radio verdadero y la inversión converge a un valor sesgado aunque el ajuste espectral global sea bueno: en nuestro experimento sintético, un único descenso converge a un radio de 2,55 mm frente a los 3,5 mm reales; ocho reinicios aleatorios reducen el error del radio al 5 %, pero viscosidad y tensión superficial permanecen degeneradas — la pérdida de magnitud no las distingue. Como direcciones para estrechar esta brecha, pérdidas perceptualmente fundamentadas como el scattering tiempo–frecuencia conjunto o la pérdida perceptual-neuronal-física [24] prometen gradientes más informativos para contenido inarmónico y no estacionario.

Fig. 5. Methods comparison: Physics matches neural on objective quality; monotonicity confirmed on 10/15 (scene, knob) pairs




Figura 4 – Físico frente a neural: veredicto de calidad y rango dinámico medio sobre el conjunto de generaciones.

Cuadro 3 – Resumen de la recuperación inversa por primitiva.

Primitiva	Error típico	Observación
Gota	radio < 0,05 %, viscosidad < 0,2 %	ninguna
Modal	frecuencia < 0,3 %, decaim. ~ 1 %	init de picos espectrales crítico
Granular	dispersión < 0,5 %; base ~ 60 %	redundancia base–dispersión
Reverb.	magnitud sí, fase no	pérdida insensible a la fase
Fricción	dureza ~ 1,5 %, velocidad ~ 4 %	decaim. del cuerpo colapsa

7. DISCUSIÓN

El marco **no aprende deliberadamente**: cada primitiva está diseñada a mano, cada modificador es función de parámetros físicos, y la cadena entera es determinista. Los beneficios son reproducibilidad, interpretabilidad y ausencia de requisitos de datos de entrenamiento; los costes son el alcance, ya que cada material e interacción requiere una decisión de modelado,

y la imposibilidad de generalizar a combinaciones realmente nuevas sin intervención humana. Vemos el marco como el *profesor* en un futuro escenario profesor–alumno: un modelo neural entrenado para invertir parámetros físicos desde grabaciones reales, con el motor físico generando supervisión bajo demanda.

Los baselines neurales con dirección latente destacan un confundente recurrente en la literatura: la monotonía espectral es necesaria pero no suficiente para el control perceptual. Un método que cambia el RMS y el centroide de forma monotónica puede aún producir audio que los oyentes no ordenan a lo largo del eje semántico pretendido. El marco físico colapsa esa brecha por construcción; la cuestión abierta — que el piloto perceptual en curso abordará — es si los oyentes coinciden.

Limitaciones. El marco está restringido a los materiales e interacciones tabulados. Los perfiles modales están afinados a mano y se beneficiarían de calibración data-driven contra respuestas al impulso reales. El modelo de líquido emplea la burbuja de Minnaert como aproximación de primer orden; estrictamente, esta resonancia describe la burbuja entrañada en el agua receptora en el instante del contacto, no una burbuja contenida en la gota en vuelo, e ignora el acoplamiento entre burbujas y los desplazamientos de frecuencia por forma e interfaz que caracterizan el estado del arte en acústica de fluidos [11, 12]; incorporar modos acoplados es una vía natural de mejora. Finalmente, la gota rodante, aunque audiblemente reconocible, es una realización de una clase: distintas superficies y formas de gota requerirían validación de parámetros aún pendiente.

8. CONCLUSIONES

Hemos presentado un marco paramétrico físicamente informado para sintetizar sonidos imposibles, con la gota rodante como caso paradigmático. El marco soporta combinaciones imposibles materia–interacción mediante primitivas en capas y un compositor genérico. Las métricas acústicas confirman control monotónico donde es físicamente aplicable, y un estudio perceptual piloto, actualmente en curso, verificará si esa monotonía cuantitativa se traduce a monotonía perceptual. Una contraparte diferenciable cierra el bucle inverso, recuperando parámetros físicos desde audio con un continuo de identificabilidad que el trabajo documenta explícitamente, desde la recuperación quirúrgica de gotas e impactos modales hasta casos mal condicionados como la propia gota rodante, cuyo cuello de botella es la estimación de frecuencia por gradiente. Situado frente al estado del arte reciente, el marco es una demostración interpretable y reproducible de modelado físico diferenciable cuya principal vía de mejora es la adopción de física de burbujas acopladas. El código, el conjunto de datos y la demostración interactiva se liberan de forma anónima para revisión y públicamente tras la aceptación.

REPRODUCIBILIDAD

Todo el audio del artículo se genera con código determinista; la cadena completa — estímulos, tablas de monotonía, figuras y comparación físico frente a neural — se ejecuta en CPU en menos de cinco minutos. Cada ajuste inverso persiste sus parámetros recuperados, errores y trayectoria de pérdida como informe JSON, de modo que las cifras de la Tabla 3 son trazables a artefactos versionados. Se acompaña además una demostración interactiva en navegador, con las primitivas portadas a una página autónoma desplegable en cualquier alojamiento estático. Código, datos y demostración se publican junto al artículo.

REFERENCIAS

- [1] A. Défossez *et al.*, “High fidelity neural audio compression,” *arXiv:2210.13438*, 2022.

- [2] A. Caillon and P. Esling, "RAVE: A variational autoencoder for fast and high-quality neural audio synthesis," *arXiv:2111.05011*, 2021.
- [3] R. Kumar *et al.*, "High-fidelity audio compression with improved RVQGAN," *NeurIPS*, 2023.
- [4] H. Liu *et al.*, "AudioLDM: Text-to-audio generation with latent diffusion models," *ICML*, 2023.
- [5] Z. Evans *et al.*, "Stable Audio Open," *Stability AI Technical Report*, 2024.
- [6] F. Roche *et al.*, "Autoencoders for music sound modeling: A comparison of linear, shallow, deep, recurrent and variational models," *Frontiers in Signal Processing*, 2021.
- [7] N. Devis *et al.*, "Continuous descriptor-based control for deep audio synthesis," *ICASSP*, 2023.
- [8] M. Minnaert, "On musical air-bubbles and the sounds of running water," *The London, Edinburgh, and Dublin Philosophical Magazine*, vol. 16, no. 104, 1933.
- [9] K. van den Doel, "Physically based models for liquid sounds," *ACM Transactions on Applied Perception*, vol. 2, no. 4, 2005.
- [10] I. Drumm, "Synthesis of bubble sounds," *Internoise*, 2010.
- [11] K. Xue, J. Aronson, D. Wang, T. Langlois, and D. L. James, "Improved water sound synthesis using coupled bubbles," *ACM Transactions on Graphics (SIGGRAPH)*, vol. 42, no. 4, 2023.
- [12] T. R. Langlois, C. Zheng, and D. L. James, "Toward animating water with complex acoustic bubbles," *ACM Transactions on Graphics (SIGGRAPH)*, vol. 35, no. 4, 2016.
- [13] S. Bilbao, *Numerical Sound Synthesis: Finite Difference Schemes and Simulation in Musical Acoustics*. Wiley, 2009.
- [14] F. Avanzini and S. Crosato, "Friction models for sound synthesis," *Proc. DAFx*, 2006.
- [15] A. Barahona-Ríos and T. Collins, "NoiseBandNet: Controllable time-varying neural synthesis of inharmonic sounds," *IEEE Trans. Audio, Speech, Lang. Process.*, 2024.
- [16] B. Lee *et al.*, "Learning control of neural sound effects synthesis from physically inspired models," *Proc. AES*, 2023.
- [17] [SoundMorpher], "SoundMorpher: A unified framework for sound morphing," *Proc. DAFx*, 2023.
- [18] Y. Wu *et al.*, "Large-scale contrastive language-audio pretraining (CLAP)," *ICASSP*, 2023.
- [19] J. Engel *et al.*, "DDSP: Differentiable digital signal processing," *ICLR*, 2020.
- [20] X. Jin *et al.*, "DiffSound: Differentiable modal sound rendering and inverse rendering for diverse inference tasks," *ACM SIGGRAPH*, 2024.
- [21] J. W. Lee *et al.*, "Differentiable modal synthesis for physical modeling of planar string sound and motion simulation," *NeurIPS*, 2024.
- [22] B. Hayes, C. Saitis, and G. Fazekas, "Sinusoidal frequency estimation by gradient descent," *arXiv:2210.14476*, 2022.
- [23] N. Uzdad *et al.*, "DiffMoog: A differentiable modular synthesizer for sound matching," *arXiv:2401.12570*, 2024.
- [24] H. Han, V. Lostanlen, and M. Lagrange, "Perceptual-neural-physical sound matching," *ICASSP*, 2023.